



2 - PROBABILIDADE

ÁREAS DA ESTATÍSTICA

1

Estatística Descritiva

(usada no processo de análise)

2

Probabilidade

(usada nos algoritmos de machine learning)

3

Estatística Inferencial

(usada para fazer inferências sobre uma população/amostra)

PROBABILIDADE

- Estudo da aleatoriedade e da incerteza (medida da incerteza).
- A probabilidade é um número que varia de 0 a 1 e que mede a chance de ocorrência de um determinado resultado. Pode ser expressa através de decimais, frações e percentagens.
- Princípio básico do aprendizado humano que é a ideia de experimento.

Experimentos Aleatórios (casuais)

Experimentos Não Aleatórios (determinísticos [resultado já é sabido])

EXPERIMENTO ALEATÓRIO

Experimento Aleatório é o fenômeno que, quando repetido inúmeras vezes em processos semelhantes, possui resultados imprevisíveis.



Experimento é qualquer atividade realizada que pode apresentar diferentes resultados. Um experimento é dito aleatório quando não conseguimos afirmar o resultado que será obtido antes de realizar o experimento. Um experimento é dito equiprovável se todos os possíveis resultados possuem a mesma chance de ocorrer.

Evento: um ou mais resultados de um experimento.

O resultado(s) são um subconjunto do espaço da amostra.

EX:

Experimento: JOGAR UM DADO

Espaço da amostra: 6

TIPOS DE PROBABILIDADE

Probabilidade Clássica

Usada quando sabemos o número de possíveis resultados do evento e podemos calcular a probabilidade do evento com a fórmula:

$$P(A) = \frac{\text{Número de possíveis resultados do evento } A}{\text{Número total de possíveis resultados dentro do espaço da amostra}}$$

Onde: $P(A)$ é a probabilidade de um evento ocorrer.

Probabilidade Empírica

Envolve conduzirmos um experimento, para observarmos a frequência com que um evento ocorre.

$$P(A) = \frac{\text{Frequência em que o evento } A \text{ ocorre}}{\text{Número total de observações}}$$

Probabilidade Subjetiva

Usamos quando dados ou experimentos não estão disponíveis para calcular a probabilidade.

REGRAS DA PROBABILIDADE

1ª Regra

Se $P(A) = 1$, então podemos garantir que o evento A **ocorrerá**

2ª Regra

Se $P(A) = 0$, então podemos garantir que o evento A **não ocorrerá**

3ª Regra

A probabilidade de qualquer evento sempre será entre **0 e 1**.

4ª Regra

A soma de todas as probabilidade para um evento simples, em um espaço de amostra, será **igual a 1**.

5ª Regra

O complemento do envento A é definido como todos os resultados em um espaço de amostra, que **não** fazem parte do envento A. Ou seja:

$P(A) = 1 - P(A')$, onde $P(A')$ é o complemento do evento A.

EVENTO E ESPAÇO AMOSTRAL

Espaço Amostral é o conjunto de possíveis resultados de um experimento ou fenômeno aleatório, representado por S .

Eventos Complementares: p (sucesso) q (insucesso) para um mesmo evento existe sempre a relação:
$$p + q = 1 \rightarrow q = 1 - p$$

Evento é qualquer subconjunto do espaço amostral S de um evento aleatório.

Eventos Independentes: quando a realização ou não de um evento não afeta a probabilidade da realização do outro evento.
Para eventos se realizarem simultaneamente: $p = p_1 \times p_2$

PROBABILIDADE CONDICIONAL : ALGORITMO NAÏVE BAYES (CLASSIFICAÇÃO)

Probabilidade Conjunta: Probabilidade de dois eventos ocorrerem juntos.

Independência: Regra Geral de Multiplicação para eventos compostos.

$$P(A \text{ e } B) = P(A) * P(B|A)$$

Probabilidade Condicional: condição previa **$P(B | A)$** pronunciamos “a probabilidade de B dado A”. Onde $P(A) \neq 0$:

$$P(B|A) = \frac{P(A \text{ and } B)}{P(A)}$$

RESUMO – PROBABILIDADE CONDICIONAL E INDEPÊNDENCIA

Ou (Or)	Em Geral	$P(A \text{ or } B) = P(A) + P(B) - P(A \text{ and } B)$
	Se eventos são mutuamente exclusivos	$P(A \text{ or } B) = P(A) + P(B)$
E (And)	Em Geral	$P(A \text{ and } B) = P(A) * P(B A) = P(A B) * P(B)$
	Se eventos são independentes	$P(A \text{ and } B) = P(A) * P(B)$

TABELA DE CONTINGENCIA

Tabela 2

Tabela de Contingência $R \times C$ no h -ésimo Estrato

Níveis do Fator	Categorias da variável de resposta						Total
	1	2	.	j	.	C	
1	n_{h11}	n_{h12}	.	n_{h1j}	.	n_{h1C}	$N_{h1\cdot}$
2	n_{h21}	n_{h22}	.	n_{h2j}	.	n_{h2C}	$N_{h2\cdot}$
\vdots	\vdots	\vdots	.	\vdots	.	\vdots	\vdots
i	n_{hi1}	n_{hi2}	.	n_{hij}	.	n_{hiC}	$N_{hi\cdot}$
\vdots	\vdots	\vdots	.	\vdots	.	\vdots	\vdots
R	n_{hR1}	n_{hR2}	.	n_{hRj}	.	n_{hRC}	$N_{hR\cdot}$
Total	$N_{h\cdot 1}$	$N_{h\cdot 2}$.	$N_{h\cdot j}$.	$N_{h\cdot C}$	$N_{h\cdot \cdot}$

DISTRIBUIÇÃO DE PROBABILIDADE – VARIÁVEL ALEATÓRIA

- ❑ Uma **Distribuição de Probabilidade** descreve a **chance** que uma variável (discreta ou continua) pode assumir ao longo de um espaço de valores.
- ❑ Uma **Distribuição de Probabilidade** é um modelo matemático que relaciona um certo valor da variável de estudo com a probabilidade de ocorrência.
- ❑ O conjunto de todos os possíveis resultados de um experimento aleatório é denominado espaço amostral.
- ❑ O resultado de um experimento **de probabilidade geralmente é uma contagem ou uma medida. Quando isso ocorre, o resultado é chamado de variável aleatória (discreta ou continua).**

TIPOS DE DISTRIBUIÇÃO DE PROBABILIDADE

Distribuição Discreta

Binomial

Poisson

Bernoulli

Geométrica

Hipergeométrica

Distribuição Contínua

Normal

Uniforme

Exponencial

Gama

t de Student

DISTRIBUIÇÃO DE PROBABILIDADE DISCRETAS

Binomial


- É utilizada para descrever cenários em que os resultados de uma variável aleatória podem ser agrupados em duas categorias. As categorias dessa distrib são classificadas como: **Sucesso (p)** ou **Falha (q)** ($p = 1 - q$)
- Media : $\mu = n * p$
- Variância: $\sigma^2 = (n.p).(1 - p)$

Onde n = número de tentativas, p = probabilidade de sucesso.

Poisson

- É usada para descrever cenários onde existe a probabilidade de ocorrência do evento em um intervalo contínuo.
- A Distribuição Poisson é caracterizada pelo parâmetro único chamado λ (lambda), que representa a taxa media de ocorrência por unidade de medida.

$$P(x) = \frac{e^{-\lambda} \cdot \lambda^x}{x!}$$



Nas **Distribuições Binomial e Poisson** os eventos são **independentes** uns dos outros. Desta forma, a probabilidade de sucesso ou de número de ocorrências, se mantém **constante**.

DISTRIBUIÇÃO DE PROBABILIDADE DISCRETAS

Hipergeométrica

- A **Distribuição Hipergeométrica** é uma distribuição de probabilidade discreta que descreve o número de sucessos numa sequência de n extrações de uma população finita, ou seja, sem reposição.
- Quando a amostragem é sem reposição, a probabilidade de **sucesso muda** durante o processo de amostragem, isso viola os requisitos para uma distribuição de probabilidade binomial. Nesse caso usamos a **Distribuição Hipergeométrica**.

$$P(x) = \frac{{N-R \choose n-x} \cdot {R \choose x}}{{N \choose n}}$$

onde:

N = Tamanho da população
 R = O número de sucessos da população
 n = Tamanho da Amostra
 x = Número de sucessos da amostra

$$\mu = \frac{nR}{N}$$

onde:

N = Tamanho da população
 R = O número de sucessos da população
 n = Tamanho da Amostra

$$\sigma = \sqrt{\frac{nR(N-R)}{N^2} \frac{N-n}{N-1}}$$

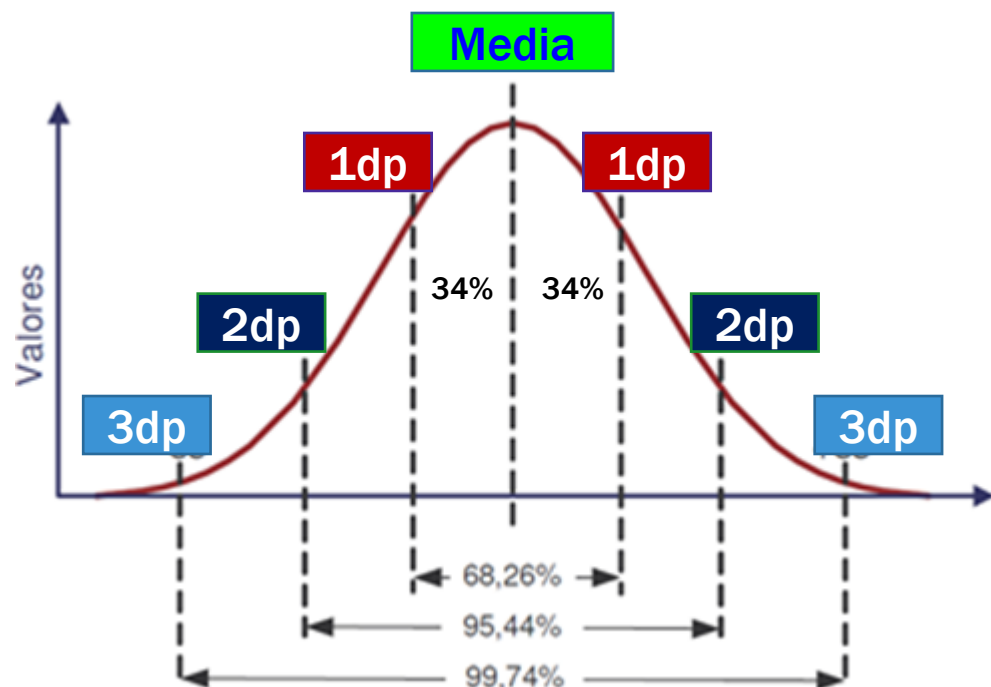
onde:

N = Tamanho da população
 R = O número de sucessos da população
 n = Tamanho da Amostra

DISTRIBUIÇÃO DE PROBABILIDADE CONTÍNUAS

Normal

- Distribuição Normal (Gaussiana) é uma curva simétrica em torno do seu ponto médio, apresentando assim seu famoso formato de sino (média = 0 e desvio padrão = 1).



Distribuição Normal é útil quando os dados tendem a estar próximos ao **centro da distribuição (próximos da média)** e quando **valores extremos (outliers)** são muito raros.

Modelos normais são definidos por dois parâmetros:

μ = média

σ = desvio padrão

Em **Machine learning** temos que **padronizar os dados**: há um Modelo Normal diferente para cada combinação de μ e σ , mas se padronizarmos nossos dados primeiro, criando **z-scores** e subtraindo da média para fazer $\mu = 0$ e dividindo pelo desvio padrão para fazer o $\sigma = 1$, então precisaremos apenas do modelo com a média 0 e o desvio padrão 1. Chamamos isso de Modelo Normal Padrão ou Distribuição Normal Padrão (Standard Normal Distribution).

DISTRIBUIÇÃO DE PROBABILIDADE CONTÍNUAS

t de Student

- Uma das principais distribuições da probabilidade, com inúmeras aplicações em inferência estatística



- **Distribuição Uniforme** – um número finito de resultados com chances iguais de acontecer. Usada quando assumimos intervalos iguais da variável aleatória que tem a mesma probabilidade.

Uniforme

- **Distribuição Exponencial** – é usada para descrever os dados quando valores mais baixos tendem a dominar a distribuição e quando valores muito altos não ocorrem com frequência.
- Na distribuição Exponencial a variável aleatória é definida como o tempo entre as duas ocorrências, sendo a média de tempo as ocorrências de $1/\lambda$.

Exponencial

DICA – DISTRIBUIÇÃO NORMAL

Obviamente, não devemos usar um modelo Normal para todos os conjuntos de dados. Se o histograma não for em forma de sino, as pontuações (scores) z não serão bem modeladas pelo modelo Normal. E a padronização não ajuda, porque a padronização não altera a forma da distribuição. Portanto, sempre verifique o histograma dos dados antes de usar o modelo Normal.

Padronizar os dados antes de apresentar à um modelo de ML:

OBS: O fato de padronizar os dados não significa que você transformou a distribuição em Normal (pois um Modelo Normal pode ter qualquer media e desvio padrão), para ter uma distribuição normal é necessário ter media 0 e desvio padrao 1.

- *Aplicar o z-score*
- *Fazer as devidas conversões*
- *No Modelo Normal aplicar as conversoes e isso irá resultar em uma distribuição normal.*

COMO DETERMINAR SE A DISTRIBUIÇÃO É NORMAL?


Para determinar se uma determinada variável aleatória segue uma distribuição normal, basta verificar se essa segue a função densidade de probabilidade, dada por:

$$f(x) = \frac{e^{-\frac{(x-\mu)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma}$$

Onde μ é a média e σ^2 é a variância de x .


A notação $N(\mu, \sigma^2)$ é usada para representar tal distribuição. Para calcularmos então a probabilidade de um resultado, basta integrar a função $f(x)$ em relação a x , com os limites de integração representando a faixa de valores que se quer obter a probabilidade. Vale notar que a integral da função densidade de probabilidade normal não possui solução analítica. Sendo assim, seu cálculo deve ser realizado através de um método numérico.

Continua



$$f(x) = \frac{e^{\frac{-(x-\mu)^2}{2\sigma^2}}}{\sqrt{2\pi\sigma}}$$

Onde μ é a média e σ^2 é a variância de x .



Para sanar tal dificuldade a função pode ser padronizada com a substituição dos parâmetros por $\mu = 0$ e $\sigma^2 = 1$. Essa abordagem é dada pela definição de uma nova variável aleatória Z , chamada de variável aleatória normal padronizada. Se x for uma variável aleatória normal com média $E(x) = \mu$ e variância $V(x) = \sigma^2$, a variável aleatória $Z = (x-\mu)/\sigma$ será uma variável aleatória normal, com $E(Z) = 0$ e $V(Z) = 1$.

Ou seja, Z é uma variável aleatória normal padrão.

Dessa forma, é possível obter a área sob a curva da normal padrão de forma analítica, e então obter a área entre dois pontos sob a curva, diretamente com o uso de uma tabela de conversão, e essa área representa uma probabilidade.

RESUMINDO

Na caracterização das distribuições de probabilidade é de grande importância a utilização de medidas que indiquem **aspectos relevantes** da distribuição, como **medidas de posição** (media, mediana e moda), medidas de **dispersão** (varância e desvio padrão) e **medidas de assimetria e curtose**.


TEOREMA DO LIMITE CENTRAL

- Esse teorema afirma que quando a amostra aumenta, a distribuição amostral da media tende a aproximar-se cada vez mais de uma distribuição normal.
- O **Teorema do Limite Central** é fundamental para a Estatística uma vez que diversos procedimentos estatísticos comuns requerem que os dados sejam aproximadamente **normais** e o TLC permite aplicar esses procedimentos úteis a populações que são fortemente **não-normais**.
- Esse teorema possibilita medir o quanto sua media amostral irá variar, sem ter que pegar outra media amostral para fazer a comparação. Ou seja, permite-nos conduzir alguns procedimentos de inferência se ter qualquer conhecimento de distribuição da população.
- Ele diz que sua **media amostral** tem uma **Distribuição Normal**, independente da aparência da distribuição dos dados originais.

TEOREMA DO LIMITE CENTRAL

- Muitos procedimentos pressupõem que uma **Distribuição Normal** é uma **Distribuição Simétrica**.
- **Assimetria** indica variação no formato de distribuição.
- **Assimetria positiva**: Implica em uma concentração maior de valores menores, e o gráfico possuirá uma cauda mais longa à direita.
- **Assimetria negativa**: Implica em uma concentração de valores maiores, e o gráfico possuirá uma cauda maior à esquerda.

Def de outlier: é um valor que está além de 3 desvios-padrão(+/-) da média. (gráfico da destri. Normal)



TEOREMA DO LIMITE CENTRAL

A área abaixo da curva Normal representa 100% de probabilidade associada a uma variável.

A probabilidade de uma variável aleatória tomar um valor entre dois pontos quaisquer é igual à área compreendida entre esses dois pontos.

Normal Padrão

